

执行摘要

本报告基于两个模型（DeepSeek V4 Flash 和 DeepSeek V3）在两组医学问答数据集（单答案 cmb-medical-qa 和多答案 cmb-medical-multi-qa）上的实验数据。关键发现如下：

- 在单答案任务上，DeepSeek V3 的准确率（90.36%）高于 DeepSeek V4 Flash（86.79%），但 McNemar 检验 p 值为 0.0755 (≥ 0.05)，差异不具有统计学显著性。
- 在多答案任务上，DeepSeek V4 Flash 的准确率（69.23%）显著高于 DeepSeek V3（57.99%），p 值为 0.000546 (< 0.05)，差异显著。
- 所有实验均无失败样本（failure_count = 0），运行稳定。
- 成本方面，DeepSeek V4 Flash 的 token 消耗量更大，但两个模型均显示零成本（可能为免费调用）。

性能分析

单答案数据集（cmb-medical-qa）

模型	准确率	95% Wilson 置信区间	平均延迟 (ms)	平均每行延迟 (ms)
DeepSeek V4 Flash	86.79%	[82.32%, 90.26%]	2360.8	2364.1
DeepSeek V3	90.36%	[86.33%, 93.29%]	1998.9	2002.2

- 准确率差异：DeepSeek V3 高出 3.57 个百分点。
- 置信区间有重叠，McNemar 检验 p = 0.0755，差异不显著。
- 在 280 对样本中，DeepSeek V4 Flash 正确而 V3 错误的有 8 例，V3 正确而 V4 错误的有 18 例。

多答案数据集（cmb-medical-multi-qa）

模型	准确率	95% Wilson 置信区间	平均延迟 (ms)	平均每行延迟 (ms)
DeepSeek V4 Flash	69.23%	[61.91%, 75.70%]	3262.1	3265.4
DeepSeek V3	57.99%	[50.45%, 65.17%]	2346.2	2349.3

- 准确率差异：DeepSeek V4 Flash 高出 11.24 个百分点。
- 置信区间无重叠，McNemar 检验 p = 0.000546，差异显著，DeepSeek V4 Flash 显著优于 DeepSeek V3。
- 在 169 对样本中，DeepSeek V4 Flash 正确而 V3 错误的有 24 例，V3 正确而 V4 错误的有 5 例。

延迟对比

- 在两个数据集上，DeepSeek V3 的延迟均低于 DeepSeek V4 Flash（单答案快约 362 ms/行，多答案快约 916 ms/行）。

成本分析

所有实验的 total_cost 均为 0.0，但 cost_unknown 标记不同：DeepSeek V4 Flash 的两个实验均为 true（成本未知），DeepSeek V3 的两个实验均为 false（成本已知且为 0）。这可能意味着 DeepSeek V4 Flash 的实际成本未被记录，而 DeepSeek V3 的调用是免费的。从 token 消耗来看：

- 单答案任务: DeepSeek V4 Flash 消耗 51,191 tokens, DeepSeek V3 消耗 29,600 tokens。
- 多答案任务: DeepSeek V4 Flash 消耗 43,166 tokens, DeepSeek V3 消耗 19,733 tokens。

DeepSeek V4 Flash 的 token 使用量约为 DeepSeek V3 的 1.7~2.2 倍, 结合延迟更长, 在相同定价下成本会更高。但由于成本均为 0, 无法直接比较真实花销。

失败分析

所有实验的 failure_count 均为

0, 表明无因提供者错误、指标错误或未处理行导致的失败样本。sample_failures

中列出了一些不匹配的示例, 但仅用于说明模型输出与正确答案的差异, 并非总错误数。例如:

- 在单答案任务中, DeepSeek V4 Flash 有 2 个样本输出为空 (因 finish_reason=length), 导致得分为 0。
- 在多答案任务中, 两个模型均存在过度预测的问题 (如输出包含多余选项), 导致与正确答案不匹配。

总体而言, 模型运行稳定, 无系统级失败。

建议

1. 任务类型选择: 对于单答案选择题, DeepSeek V3 与 V4 Flash 性能差异不显著, 但 V3 延迟更低, 成本更优; 对于多答案选择题, DeepSeek V4 Flash 显著优于 V3, 建议优先使用 V4 Flash。
2. 输出截断问题: DeepSeek V4 Flash 在单答案任务中出现了因 finish_reason=length 导致空输出的情况, 建议检查模型 max_tokens 设置或调整 prompt 以鼓励完整输出。
3. 成本监控: 目前 DeepSeek V4 Flash 的成本信息缺失, 建议启用成本核算, 以便进行更完整的性价比分析。
4. 多答案任务优化: 两个模型在多答案任务中均偶有“多选”或“漏选”的情况, 可考虑针对输出格式增加约束 (如强制输出逗号分隔的选项列表), 并针对多答案场景进行微调或 prompt 优化。

下一步行动

1. 验证输出截断问题: 对 DeepSeek V4 Flash 在单答案任务中的空输出样本进行复现, 调整 max_tokens 或 prompt 后重新测试。
2. 扩展多答案测试: 在更多多答案医学数据集上评估 DeepSeek V4 Flash, 确认其优势是否泛化。
3. 成本评估: 获取 DeepSeek V4 Flash 的实际定价, 结合 token 消耗和延迟, 计算并对比两个模型的成本效益。
4. 统计显著性确认: 随着更多数据加入, 重新计算 McNemar 检验, 以确认单答案任务中差异是否可能变得显著。
5. 错误模式分析: 基于 sample_failures 中的错误案例, 进行更细粒度的错误类型分类 (如知识错误、逻辑错误、格式错误), 为模型优化提供方向。