

AI 评测报告

执行摘要

本报告覆盖 2 个实验，总花费 \$0，共消耗 7692 个令牌，累计运行 104473 毫秒。

综合准确率最高的是 DeepSeek V3 (Qiniu) | humaneval-coding (DeepSeek V3 (Qiniu))，达到 100.0%。

性能分析

实验	模型	准确率	覆盖率	失败率	平均延迟(毫秒)	已评分行数	失败数
DeepSeek V4 Flash (Qiniu)	humaneval-coding	deepseek/deepseek-v4-flash	90.00	100.00	0.00	5192.00	10
DeepSeek V3 (Qiniu)	humaneval-coding	DeepSeek V3 (Qiniu)	100.00	100.00	0.00	4908.80	10

成本分析

总花费：\$0，共 7692 个令牌。

最省钱的实验：DeepSeek V4 Flash (Qiniu) | humaneval-coding (\$0.00, deepseek/deepseek-v4-flash)。

- DeepSeek V4 Flash (Qiniu) | humaneval-coding: \$0.00 (5016 个令牌)
- DeepSeek V3 (Qiniu) | humaneval-coding: \$0.00 (2676 个令牌)

失败分析

在检查的结果中未检测到失败样本。

建议

在对准确率敏感的场景中，采用 DeepSeek V3 (Qiniu) (DeepSeek V3 (Qiniu) | humaneval-coding) 作为基线 (实测最高准确率为 100.0%)。

在对成本敏感的路径中，可考虑 deepseek/deepseek-v4-flash (\$0.00) 作为更省钱的替代方案。

排查 DeepSeek V4 Flash (Qiniu) | humaneval-coding —— 其失败样本数最多，可能需要调整提示词或数据。

下一步行动

- 逐个实验查看「性能分析」与「失败分析」部分。
- 在质量关键处推广使用准确率最高的模型。
- 针对失败率偏高的实验，调优提示词或筛选逻辑。
- 应用改动后重新生成本报告，以跟踪改进情况。