

执行摘要

- 本评估比较了 GPT-4o mini (OpenRouter)、Doubao Seed 2.0 Pro (Qiniu) 与 DeepSeek V3 (Qiniu) 三个模型在两个数据集上的表现：THUCNews 新闻分类（120 条样本）和 ceval-qa 问答（61 条样本）。
- 在准确率方面，Doubao Seed 2.0 Pro 在两个数据集上均取得最高分：THUCNews 为 93.33%，ceval-qa 为 91.80%。DeepSeek V3 在 THUCNews 上为 84.17%（与 GPT-4o mini 持平），在 ceval-qa 上为 70.49%，显著优于 GPT-4o mini 的 55.74%。
- 在延迟方面，DeepSeek V3 平均延迟最低（约 1.2 秒/请求），Doubao Seed 2.0 Pro 延迟最高（ceval-qa 上平均达 12.56 秒/请求）。
- 在成本方面，仅 GPT-4o mini 有实际计费数据；THUCNews 实验总成本 14.65 美元，ceval-qa 实验总成本 1.18 美元。Doubao 与 DeepSeek 成本记录为 0。
- 所有实验覆盖率均为 100%，系统级失败率（provider 错误、指标错误）为 0%，但存在部分模型输出为空或分类错误的情况。

性能分析

模型	数据集	准确率	平均延迟 (ms)	每行处理时间 (ms)	总 Token 数	覆盖率
GPT-4o mini	THUCNews	84.17%	1556.9	1940.5	97,065	100%
Doubao Seed 2.0 Pro	THUCNews	93.33%	5340.8	5845.5	111,301	100%
DeepSeek V3	THUCNews	84.17%	1199.7	1203.4	83,315	100%
GPT-4o mini	ceval-qa	55.74%	1685.5	1771.6	7,573	100%
Doubao Seed 2.0 Pro	ceval-qa	91.80%	12564.1	13552.1	43,729	100%
DeepSeek V3	ceval-qa	70.49%	1207.8	1211.0	6,499	100%

- 准确率对比：Doubao Seed 2.0 Pro 在两个任务上均表现最佳，尤其在 ceval-qa 上领先第二名约 21 个百分点。DeepSeek V3 在 THUCNews 上与 GPT-4o mini 完全相同（84.17%），但在 ceval-qa 上高出 GPT-4o mini 约 15 个百分点。
- 延迟与吞吐量：DeepSeek V3 在两组实验中每行处理时间均约 1.2 秒，吞吐量最高（约 0.83 行/秒）。GPT-4o mini 居中（每行约 1.8–1.9 秒）。Doubao 最慢，THUCNews 上每行 5.85 秒，ceval-qa 上每行 13.55 秒，可能不适合实时或高频调用。
- Token 消耗：在 THUCNews 上，Doubao 消耗 Token 最多（111,301），GPT-4o mini 次之（97,065），DeepSeek 最少（83,315）。ceval-qa 上，Doubao 消耗 43,729 Token，远高于 GPT-4o mini 的 7,573 和 DeepSeek 的 6,499，表明 Doubao 可能生成了更长的推理内容。

成本分析

模型	数据集	总成本 (美元)	每行成本 (美元)	每千 Token 成本 (美元)
GPT-4o mini	THUCNews	14.6511	0.1221	0.151
GPT-4o mini	ceval-qa	1.17645	0.0193	0.155
Doubao Seed 2.0 Pro	THUCNews	0.0	0.0	0.0

模型	数据集	总成本 (美元)	每行成本 (美元)	每千 Token 成本 (美元)
Doubao Seed 2.0 Pro	ceval-qa	0.0	0.0	0.0
DeepSeek V3	THUCNews	0.0	0.0	0.0
DeepSeek V3	ceval-qa	0.0	0.0	0.0

- 仅 GPT-4o mini 有成本数据：THUCNews 上每行约 0.122 美元，ceval-qa 上每行约 0.019 美元。每千 Token 成本在两个数据集上基本一致（约 0.15 美元）。
- Doubao 和 DeepSeek 的成本记录为 0，可能来自免费额度、内部计价未记录或特定商务协议。虽然表面上零成本，但在实际生产环境中应谨慎对待，需补充计费数据才能进行完整的成本效益对比。
- 若以 GPT-4o mini 的成本为基准，处理 120 条新闻分类需约 14.65 美元，处理 61 条问答仅需约 1.18 美元，说明长文本（新闻）对成本影响显著。

失败分析

- 所有实验的 failure_rate 均为 0%，provider_errors 和 metric_errors 均为 0，系统级运行未出现中断。但各实验的 failures 列表记录了评分不匹配的样本（即模型输出与标准答案不一致），以下分析基于这些样本。
- THUCNews 新闻分类错误模式：
 - 类别混淆常见于「时政 → 财经」、「房产 → 财经 / 时政」、「时尚 → 娱乐」。
 - 例如，row_idx 1（时政新闻）被 GPT-4o mini 和 Doubao 均误判为「财经」；row_idx 11（时尚内容）被 GPT-4o mini 和 DeepSeek 均误判为「娱乐」。
 - 存在空输出现象：GPT-4o mini 有 3 次（row_idx 24、32、33），Doubao 有 1 次（row_idx 1），模型未返回任何分类标签，导致得分为 0。DeepSeek 在该任务无空输出。
- ceval-qa 问答错误模式：
 - 错误集中在计算机网络（如 TCP 确认号计算、交换技术判断）和语言学（构词法、音素区别）等专业知识点。
 - row_idx 9（TCP 确认号）三个模型均未答对：GPT-4o mini 选 C，Doubao 输出为空，DeepSeek 选 D，而正确答案为 B。
 - 同样存在空输出：Doubao 在 row_idx 9 输出为空；GPT-4o mini 和 DeepSeek 未出现空输出。
 - 整体上，ceval-qa 的准确率普遍低于 THUCNews（除 Doubao 外），说明模型在专业领域推理上仍有明显短板。
- 空输出风险：空输出集中在 Doubao 和 GPT-4o mini 上，可能是模型未遵守“仅输出答案”的指令，或生成了被解析器丢弃的额外内容。这是一个需要优先解决的质量问题。

建议

- 优先高准确率场景：推荐使用 Doubao Seed 2.0 Pro，其在两个数据集上准确率均为最高。但需接受其高延迟（平均 5–12

秒)，适合离线批量处理或异步任务。

- 平衡延迟与准确率：DeepSeek V3 在 THUCNews 上达到与 GPT-4o mini 相同的准确率，且延迟最低；在 ceval-qa 上准确率显著高于 GPT-4o mini。若系统对响应时间有要求，DeepSeek V3 是更优选择。
- 谨慎使用 GPT-4o mini：其在 ceval-qa 上准确率不足 60%，且 THUCNews 实验产生了相对较高的成本。仅在需要其特定生态或接口能力时考虑使用。
- 修复空输出问题：在提示词中明确要求“必须返回一个分类标签”，并在后处理中增加空值兜底逻辑（如重试一次或返回默认类别）。同时建议对输出格式进行结构化约束（如 JSON）。
- 针对混淆类别优化：对「时政 vs 财经」「房产 vs 财经」「时尚 vs 娱乐」等高频混淆对，可增加 few-shot 示例或收集更多该类别数据做针对性微调。

下一步行动

1. 扩大评估样本量：当前每个数据集仅 120/61 条，统计波动较大。建议扩展至 500+ 条以获取更可靠的准确率估计和置信区间。
2. 补全成本数据：为 Doubao 和 DeepSeek 接入实际计费或估算成本，完成三方总拥有成本（TCO）对比。
3. 构建混淆矩阵：基于全量输出统计各类别间的误判分布，定位系统性偏置，并据此调整类别定义或提示词。
4. 多版本 Prompt 实验：当前所有实验 prompt_version=1，可设计 v2（增加格式约束、示例、推理步骤）对比对准确率和空输出率的影响。
5. 延迟优化：对 Doubao 尝试批处理、流式输出或降低最大 Token 数来压缩响应时间；对 DeepSeek 可进一步压测高并发场景下的稳定性。
6. 专业领域专项评估：针对 ceval-qa 中的计算机网络、语言学等薄弱科目，引入领域知识库或 RAG 增强，并重新评测。