

执行摘要

本次评估基于两个模型（DeepSeek V4 Flash 与 DeepSeek V3）在三个数据集（ceval-qa、thucnews-classification、humaneval-coding）上的对比实验数据。核心发现如下：

- DeepSeek V4 Flash 在知识问答（ceval-qa）和新闻分类（thucnews-classification）上准确率更高，分别达到 86.89% 和 89.17%，优于 DeepSeek V3 的 70.49% 和 84.17%。但在编码任务（humaneval-coding）上，V4 Flash 的准确率为 95.00%，低于 V3 的 100%。
- DeepSeek V3 在延迟上表现显著优于 V4 Flash，所有任务的平均延迟仅为 V4 Flash 的 20%~50%，且 token 消耗更少。
- 两个模型在本次实验中的 总成本均为 0（免费调用），但 V4 Flash 消耗的 token 总量（164,672）高于 V3（104,132）。
- 失败分析显示，V4 Flash 在知识问答和编码任务中各有 3 个失败案例，V3 在知识问答和分类任务中各有 5 个和 8 个失败案例，但 V4 Flash 在编码任务的失败数量（3 个）多于 V3（0 个）。

综合来看，DeepSeek V4 Flash 更适合对准确率要求高的知识性任务，而 DeepSeek V3 在延迟敏感或编码任务中更具优势。建议根据实际业务场景选择模型，并针对失败案例进行针对性优化。

性能分析

模型	数据集	准确率	平均延迟 (ms)	每行平均耗时 (ms)	总 Token 数	运行时 (ms)
DeepSeek V4 Flash	ceval-qa	86.89%	6216.6	9171.4	34,412	559,454
DeepSeek V3	ceval-qa	70.49%	1369.4	1372.2	6,499	83,704
DeepSeek V4 Flash	thucnews-classification	89.17%	4236.6	4740.0	90,680	568,797
DeepSeek V3	thucnews-classification	84.17%	1314.8	1318.1	83,315	158,174
DeepSeek V4 Flash	humaneval-coding	95.00%	8609.6	10734.2	39,580	644,050
DeepSeek V3	humaneval-coding	100.00%	4475.1	4605.0	14,318	276,302

- 准确率：V4 Flash 在 ceval-qa 和 thucnews-classification 上分别高出 V3 16.4 和 5 个百分点；但在 humaneval-coding 上，V3 完美通过所有测试（100%），V4 Flash 仅达到 95%。
- 延迟：V3 在所有任务上的平均延迟均远低于 V4 Flash，差距约 3~6 倍。尤其在 ceval-qa 上，V3 延迟（1369 ms）仅为 V4 Flash（6217 ms）的 22%。
- Token 消耗：V4 Flash 消耗的 token 总数是 V3 的 1.58 倍，主要增量来自 thucnews 任务（90,680 vs 83,315）和 ceval 任务（34,412 vs 6,499）。在编码任务上，V4 Flash 消耗 token 是 V3 的 2.76 倍。

成本分析

所有实验的 total_cost 均为 0.0，表明两个模型在当前调用方式下均为免费，未产生直接费用。因此，成本差异主要体现在 token 消耗量和运行时间上：

- Token 消耗：V4 Flash 总消耗 164,672 token，V3 总消耗 104,132 token。若未来按 token 计费，V4 Flash 的潜在成本约为 V3 的 1.58 倍。

- 运行时间：V4 Flash 总运行时间约 1,772,301 ms，V3 总运行时间约 518,180 ms，V4 Flash 耗时是 V3 的 3.42 倍。这意味着在单位时间内，V3 能处理更多请求，从而降低基础设施成本。

失败分析

模型	数据集	失败数	失败原因概要
DeepSeek V4 Flash	ceval-qa	5	计算机网络（2 例：位填充、TCP 确认）、中文语言文学（2 例：音素区别、楷书
DeepSeek V3	ceval-qa	5	计算机网络（2 例：TCP 确认、交换技术）、中文语言文学（3 例：构词方式、音
DeepSeek V4 Flash	thucnews-classification	6	时尚误判为娱乐（1 例）、房产误判为时政（1 例）、时政误判为教育（1 例）、时
DeepSeek V3	thucnews-classification	8	房产误判为财经（2 例）、时尚误判为娱乐（1 例）、教育误判为财经（1 例）、房
DeepSeek V4 Flash	humaneval-coding	3	代码生成失败（2 例输出为空字符串，1 例输出包含多余 markdown 代码块导致测
DeepSeek V3	humaneval-coding	0	全部通过

- 常见失败模式：两个模型在 ceval-qa 上均对计算机网络和中文语言文学存在误判，说明这些领域知识仍是挑战。在 thucnews 分类中，V4 Flash 更易将“房产”类误判为“时政”，而 V3 更易将“房产”误判为“财经”。在编码任务中，V4 Flash 出现空输出和格式错误，V3 则未出现任何失败。
- 空输出问题：V4 Flash 在 ceval-qa 第 9 行（TCP 确认）和 humaneval-coding 第 32、39 行输出为空字符串，需排查模型是否因 token 截断或推理异常导致不生成有效内容。

建议

- 任务选择模型：
 - 对于知识问答、分类等文本理解任务，优先使用 DeepSeek V4 Flash，其准确率更高。
 - 对于编码生成任务，推荐使用 DeepSeek V3，其准确率 100% 且延迟更低。
 - 若对延迟敏感（如实时推理），V3 是更优选择。
- 优化失败案例：
 - 针对 ceval-qa 的失败，可考虑提供更清晰的提示词（如要求输出选项字母），或对模型进行领域微调。
 - 对 thucnews 分类的混淆（如“房产” vs “时政”），可增加示例或调整分类标签定义。
 - 检查 V4 Flash 空输出问题，通过设置 max_tokens 或重试机制减少此类错误。
- 成本控制：
 - 当前免费，但未来若计费，V3 的 token 效率更高，适合大规模部署。
 - 监控 token 消耗，在提示词中精简上下文以降低 V4 Flash 的 token 使用量。

下一步行动

- 深入分析失败案例：对 V4 Flash 在 humaneval-coding 中的空输出和格式错误进行复现，检查是否与模型版本或参数设置有关。
- 扩展测试集：在更多数据集（如数学推理、长文本摘要）上评估两个模型，以验证性能差异的普适性。
- 对比微调效果：对 V4 Flash 在 ceval-qa 上进行简单指令微调，观察准确率提升幅度。

4. 监控投入生产：若选择 V4 Flash 用于生产，需建立延迟告警和重试策略，确保空输出情况被及时处理。
5. 成本模拟：基于实际 token 单价，为两个模型估算不同规模下的月度成本，辅助预算决策。